

# 数据视角下的低光原始数据可学习性增强图像去噪

## 摘要

低光照原始图像降噪是计算摄影中的一项重要任务，其中基于学习的方法已经成为主流解决方案。学习基础方法的标准范式是学习配对的真实数据之间的映射关系，即低光照噪声图像和其干净对应图像之间的关系。然而，有限的数据量、复杂的噪声模型和尚未发展完善的数据质量构成了学习配对真实数据之间映射关系的可学习性瓶颈，限制了学习基础方法的性能。为了突破这一瓶颈，我们引入了一种通过噪声建模改进配对真实数据的可学习性增强策略，用于低光照原始图像降噪。我们的可学习性增强策略集成了三种高效方法：拍摄噪声增强（SNA）、暗部阴影校正（DSC）和一种改进的图像采集协议。具体而言，SNA 通过增加配对真实数据的数据量来提高数据映射的精度，DSC 通过降低噪声复杂性来提高数据映射的准确性，而改进的图像采集协议通过提高配对真实数据的数据质量来提高数据映射的可靠性。同时，基于改进的图像采集协议，我们构建了一个新的用于低光照原始图像降噪的数据集。对公共数据集和我们的数据集进行的实验证明了可学习性增强策略的优越性。

**关键词：**计算成像；低光照降噪；噪声建模；数据集；

## 1 引言

计算摄影作为一种提高图像质量的高效方式，长期以来已经被应用于各种摄像机中。然而，在低光条件下，无法避免的噪声显著限制了计算摄影在性能上的表现。因此，低光照原始图像降噪在计算摄影中扮演着重要角色，已经在移动摄影 [1], [2]，天文学 [3], [4] 和显微镜学 [5] 等领域进行了广泛研究。随着计算能力的扩大，基于学习的方法近年来取得了巨大进展，已经成为低光照原始图像降噪的主流解决方案 [6], [7]。基于学习的方法的标准范式是通过神经网络学习配对的真实数据之间的映射关系，即低光照噪声图像和其干净对应图像之间的映射 [8]，可学习性描述了神经网络近似数据映射的难度 [9]。

增强数据映射的可学习性是提高降噪性能的最有效方式。从数据角度看，图像降噪中数据映射的可学习性高度依赖于配对真实数据的数据量、噪声模型的复杂性和配对真实数据的质量。大多数关于图像降噪的研究 [10–18] 表明，真实噪声遵循与传感器成像过程相关的复杂分布，导致数据映射的准确性较低。其次，由于噪声和不对齐问题，真实数据的质量通常受到损害，导致数据映射的可靠性较低。复杂的噪声模型、有限的数据量和不成熟的数据质量共同导致了在低光照原始图像降噪中真实数据映射的困境。

近期的研究尝试通过根据噪声建模合成数据，而不是使用配对真实数据来解决映射困境 [19], [20], [21]。这种方法可以合成新的噪声和干净图像对以用于学习数据映射。然而，由

于某些噪声部分（例如读噪声）远未能够准确建模，合成数据不可避免地会偏离真实数据，失去在实际场景中的效力。因此，真实数据的脆弱可学习性仍然是低光照原始图像降噪的瓶颈。在本文中，我们提出了一种用于低光照原始图像降噪的可学习性增强策略。我们重新审视降噪任务，从数据角度出发，根据噪声建模改进了配对真实数据。

我们的第一个观察是，拍摄噪声仅与干净图像相关，并且可以用泊松分布 [22], [23] 准确建模。我们提出了“Shot Noise Augmentation (SNA)”方法来增加配对真实数据的数据量。SNA 首先将真实数据与拍摄噪声模型相结合，合成新的噪声-干净数据对，然后通过数据增强来促进数据映射精度。由于数据量的增加，映射可以生成具有清晰纹理的降噪图像。

我们的第二个观察是，暗部阴影保持时间稳定，并且可以用像素偏差 [24], [25] 来建模。我们提出了“Dark Shading Correction (DSC)”方法来解耦真实噪声模型。DSC 首先校准暗部阴影，然后在噪声图像中进行校正，以促进数据映射的准确性。由于降低了噪声复杂性，映射可以生成具有准确颜色的降噪图像。

我们的第三个观察是，现有的低光照原始图像采集协议在数据质量方面尚未发展完善，包括由于噪声和不对齐导致的数据缺陷。我们提出了一个高质量的图像采集协议和一个“Low-light Raw Image Denoising (LRID)”数据集。该协议首先改进了图像捕获设置，然后估计了干净的参考图像，以提高数据映射的可靠性。由于数据质量的提高，映射可以生成具有更少伪影的降噪图像。

这些想法源于将配对真实数据和噪声建模集成起来，这被认为是低光照原始图像降噪的两个平行方向。通过在公共数据集和我们的数据集上进行大量实验，我们证明了我们的可学习性增强策略的卓越性能。我们的主要贡献总结如下：

1. 我们从数据的角度出发，提出了通过根据噪声建模改进配对真实数据来增强可学习性的想法，用于低光照原始图像降噪。
2. 我们引入了一种新颖的拍摄噪声增强方法，通过数据增强来增加配对真实数据的数据量，从而提高数据映射的精确度。
3. 我们提出了一种新颖的暗部阴影校正方法，通过解耦噪声来降低噪声复杂性，从而提高数据映射的准确性。
4. 我们开发了一个高质量的图像采集协议，并构建了一个低光照原始图像降噪数据集，通过改善配对真实数据的数据质量，提高了数据映射的可靠性。
5. 我们在公共数据集和我们的数据集上，通过定量结果和视觉质量的两方面，展示了我们方法的卓越性能。

我们的代码和数据集已在 [26] 上发布。此外，我们进一步发展了基于暗部阴影的噪声校准方法，并提供了用于校准的数据。我们相信这对进一步研究低光照原始图像降噪具有意义。这项工作在我们的初步工作 [27] 的基础上有重大改进。首先，我们开发了一个高质量的图像采集协议，以提高配对真实数据的数据质量。基于该协议，我们构建了一个低光照原始图像降噪数据集，提高了数据映射的可靠性。其次，我们分析了拍摄噪声增强方法的性质，并基于真实读取噪声样本扩展了应用策略。扩展的设计可以提高降噪后的图像的细节清晰度。此外，我们开发了线性暗部阴影模型，并深入分析了 DSC 的稳健性和泛化性。我们进一步探讨了 DSC 在基于物理的噪声建模中的扩展，带来了巨大的降噪性能提升。最后，我们在更多的数据集上评估了我们的方法，并进行了更广泛的实验，展示了我们方法的潜在广泛应用价值。

## 2 相关工作

### 2.1 低光原始图像去噪

传统的去噪方法通常依赖于图像先验，如平滑性 [28], [29]、自相似性 [30], [31], [32]，稀疏性 [33], [34] 和低秩 [35]。与预设图像先验不同，基于学习的方法直接通过深度神经网络学习从噪声图像到其干净对应物（成对的真实数据）的映射。近期研究表明，基于学习的方法在去噪性能上远远超过传统方法 [8], [36], [37]。然而，这些基于学习的方法常常因复杂的噪声模型和有限的数据量而难以学习。为了解决脆弱的学习能力问题，一些研究专注于改进噪声模型的真实性，以绕过对成对真实数据的需求。传感器噪声通常被分为“拍摄噪声”和“读取噪声”。泊松-高斯模型常用于模拟低光照原始图像去噪中的真实噪声 [38]。为了确保噪声模型可以适用于不同相机下的方差稳定化转换（VST）[39], [40]，提出了相应方法。ELD 是一种基于物理的噪声建模方法，用于极低光照摄影，其效果与成对真实数据相当 [20], [21]。然而，由于其对独立同分布时间噪声的假设与真实的空间噪声（如固定图案噪声）不同，ELD 的局限性仍然存在。因此，ELD 的视觉质量仍然受到残余图案噪声的影响，这表明了真实数据的重要性。尽管存在这些局限性，噪声建模在突破成对真实数据的可学习性瓶颈方面显示出巨大潜力。光电反应的物理特性是明确的，从而导致了对拍摄噪声的可靠分析 [22], [23], [41]。相比之下，读取噪声更加复杂，在成像社区中还没有共识 [24], [41], [42], [43], [44], [45]。在相机中提取和建模所有类型的噪声源极其困难。一种解决方案是将真实数据与噪声建模结合使用。SFRN 使用可靠的拍摄噪声进行噪声建模，并从真实的暗帧中采样复杂的读取噪声，这解放了成对真实数据的数据量 [46]。然而，SFRN 继承了真实读取噪声的复杂性，导致数据映射学习过程具有挑战性。我们发现数据映射的高复杂性主要是由于暗阴影 [25]。为了解决有限的数据量和复杂的噪声模型问题，我们根据噪声建模重新整合成对真实数据。解决脆弱的学习能力问题，对提高去噪性能，尤其是在低光照条件下，具有重要意义。

### 2.2 原始图像去噪数据集

与标准 RGB (sRGB) 图像相比，原始图像处理简单高效。近年来，随着计算摄影需求的增加，原始图像去噪数据集也得到了发展。DND 数据集 [47] 包括来自 4 种不同相机的 50 个场景的数据，并引入了一种新的原始图像获取协议，主要由在高和低 ISO 下拍摄的图像对组成。然而，DND 数据集中的大部分数据是在正常光照条件下收集的，噪声水平相对较低。SIDD 数据集 [48] 包括来自 4 种不同智能手机相机在 10 个室内场景下的数据，这些场景有四种光照条件，主要由多帧融合结果和噪声图像（参考帧）组成。SIDD 数据集进一步发展了图像获取协议，目前是最广泛使用的基准。然而，SIDD 的场景多样性有限，特别是缺乏低光照去噪的主要应用场景，如室外场景，这在最近的研究中被证明是必要的 [49]。

与我们的工作更为相关的是 SID 数据集 [8]，它包括来自 2 种不同相机在 424 个低光照场景中的数据，主要由在不同曝光时间拍摄的图像对组成。SID 数据集提供了第一个大规模的低光照原始图像去噪训练数据集，具有成对的真实数据。然而，SID 数据集的图像获取协议实际上存在许多数据缺陷，如高 ISO 的显著噪声和基准真相中的运动模糊。这些数据缺陷导致了数据的脆弱学习能力。ELD 数据集 [21] 包括来自 4 种不同相机在 10 个室内场景中的数据，主要由在不同曝光时间和不同 ISO 下拍摄的图像对组成。ELD 数据集可以解决没有运

动的室内场景中的数据缺陷，但所提出的图像获取协议无法推广到室外场景，因为缺乏对齐。

我们专注于为室外场景开发图像获取协议。我们的图像获取协议解决了之前数据集中影响学习能力的各种数据缺陷。我们提出了一种新的图像获取协议和低光照原始图像去噪数据集，通过提高成对真实数据的数据质量来促进数据映射的可靠性。

### 3 本文方法

#### 3.1 本文方法概述

从数据的角度来看，成对真实数据之间的映射缺乏可学习性，这限制了基于学习的去噪方法的性能。有限的数据量和复杂的噪声模型是导致成对真实数据脆弱学习能力的两个主要原因。为了提高可学习性，有必要在保持真实噪声模型的同时增加数据量和降低噪声复杂性。然而，解决这些问题具有挑战性，因为成对真实数据中的真实噪声模型是一个“黑箱”。我们提出了一种数据增强方法来增加数据量。数据增强利用了拍摄噪声模型的可加性质，即泊松分布。我们提出了一种噪声解耦方法来减少噪声复杂性。噪声解耦将读取噪声模型分解为简单形式，即时间稳定的暗阴影和时间变化的读取噪声。我们的学习能力增强策略解决了有限的数据量和复杂的噪声模型问题，同时保留了真实噪声模型，从而增强了数据映射的可学习性。

这个段落描述了学习能力增强的框架，如图 1 所示。SNA 是一种基于拍摄噪声模型的数据增强方法。我们通过增加拍摄噪声来持续合成新的噪声-清晰数据对，以此增加数据量。DSC 是一种基于读取噪声模型的噪声解耦方法。我们首先校准暗阴影，然后在成对真实数据中进行校正以降低噪声复杂性。SNA 增强的数据具有与原始数据不同的噪声参数，但共享相同的噪声模型。通过 DSC 解耦的数据可以通过将解耦数据相加来还原为原始数据。因此，我们的策略可以在不破坏真实噪声模型的情况下增强数据映射的可学习性。

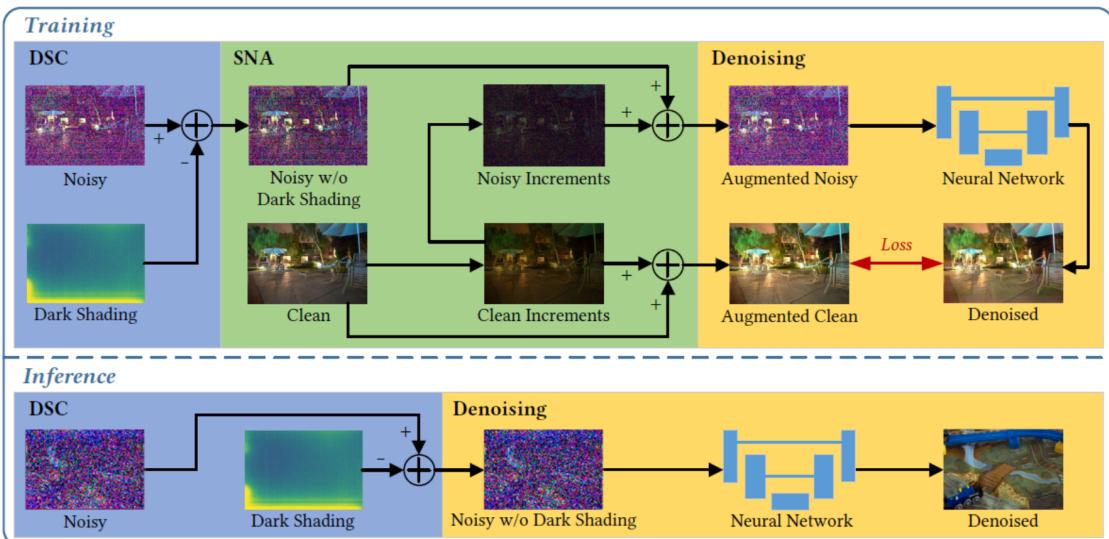


图 1. 降噪方法框架

### 3.2 散粒噪声数据增强

由于光的量子性质以及收集的光子数的不确定性，所有像素的  $(I + N_p)$  遵循泊松分布其中  $P$  表示泊松分布。现在我们假设有一个干净信号增量，我们的目标是找到相应的噪声信号增量对于成对的真实数据，干净图像  $D_c$  是已知的。通过 SNA 增加数据量，神经网络可以精确地拟合成对真实数据之间的数据映射，从而促进具有清晰纹理的去噪图像。

$$\begin{aligned} F(D_c + \Delta D) &= KP\left(\frac{D_c + \Delta D}{K}\right) + F_{\text{read}} \\ &= KP\left(\frac{D_c}{K}\right) + KP\left(\frac{\Delta D}{K}\right) + F_{\text{read}} \\ &= F(D_c) + KP\left(\frac{\Delta D}{K}\right) \end{aligned} \quad (1)$$

在干净图片中引入增量后，对于带噪图片，可以获得

$$\Delta N \sim KP\left(\frac{\Delta D}{K}\right) \quad (2)$$

遵循泊松分布的独立变量满足加法性质，但是，它们的减法结果不再符合泊松分布。因此，SNA 具有一种属性，即基础图像（即噪声图像  $D_n$ ）的信号只能单调增加，这导致了一个实际挑战，即 SNA 可以产生比基础图像更亮的图像，但不能产生更暗的图像。这个限制限制了 SNA 在暗场景中的增强能力。我们进一步提出了一个解决方案，简单地在极暗环境中捕获成对的噪声图像，即收集仅包含读取噪声的噪声暗帧。当场景辐照度  $I$  为 0 时，可以将其视为方程的一个特殊情况，其中暗帧被视为噪声图像  $D_n$ ，并且噪声信号增量根据以下方式采样然而，仅仅采样暗帧是不够的，因为在量化后缺乏信息。为了解决信息缺失的问题，我们采用了 SFRN [46] 中提出的高位恢复策略，以帮助暗帧在这种情况下准确地代表真实的读取噪声。总的来说，我们通过引入暗帧来扩展 SNA 的应用策略，这可以促进具有清晰细节的去噪图像。

增强过程如程序 1 所示。首先，我们随机抽取一组参数以获取干净图像  $D_c$ ，从而获得增强的干净图像  $D_c$ 。其次，我们通过计算干净图像  $D_c$  和增强的干净图像  $D_c$  的差异来获得干净信号增量  $\Delta D$ 。然后，我们根据干净信号增量合成噪声信号增量  $\Delta N$ 。最后，我们将合成的噪声信号增量加到真实的噪声图像  $D_n$  上，以获得增强的噪声图像  $D_n$ 。增强的噪声图像  $D_n$  和增强的干净图像将构成一个新的噪声-干净图像对。干净信号增量的具体参数抽样策略可以自由设计，但仍需遵循一些基本原则：(1) 干净信号增量应为非负数，以确保可以应用泊松抽样；(2) 有必要确保 SNA 不会引入明显的色偏和大规模过曝。基于上述原则，我们选择根据干净图像  $D_c$  合成干净信号增量。我们只增强颜色通道比例和全局亮度，以模拟真实场景，这指的是白平衡建模 [19]。首先，我们随机初始化符合高斯分布的因子，其中是高斯分布的参数。然后，我们基于裁剪后的随机抽样绿色通道的增益。接下来，我们根据随机因子和绿色通道的增益选择红色通道的增益和蓝色通道的增益。最后，增益参数用于增益不同的颜色通道，并且它们都被裁剪到适当的值范围以满足基本设计原则。

---

**Algorithm 1** Shot Noise Augmentation

---

**Input:**  $D_c, D_n$ **Output:**  $\tilde{D}_c, \tilde{D}_n$ **function** PARAMETERSAMPLING( $\delta, \sigma$ ) $g \sim \mathcal{N}(\delta + 1, \sigma); r, b \sim \mathcal{N}(1, \sigma)$  $Gain_g \leftarrow \text{clip}(g)^{\frac{4\delta+1}{1}}$  $Gain_r \leftarrow \text{clip}(Gain_g \times r)^{\frac{4\delta+1}{1}}$  $Gain_b \leftarrow \text{clip}(Gain_g \times b)^{\frac{4\delta+1}{1}}$  $Gain \leftarrow (Gain_r, Gain_g, Gain_b)$ **return**  $Gain$ **end function** $Gain \leftarrow \text{PARAMETERSAMPLING}(\delta, \sigma)$  $\tilde{D}_c \leftarrow D_c \times Gain$  $\Delta D \leftarrow \tilde{D}_c - D_c$  $\Delta N \sim KP\left(\frac{\Delta D}{K}\right)$  $\tilde{D}_n \leftarrow D_n + \Delta N$ 

原始图像去噪在数据增强方面提出了独特的挑战。原始图像的拜耳图案和打破真实噪声模型的风险可能会在训练和应用域之间造成差距。因此，原始图像去噪方法在使用有限的数据增强技术（如旋转和翻转）时必须谨慎，这些技术通常缺乏足够的数据量 [50]。此外，这些方法在促进噪声信号多样性方面也不足，这对于拟合数据映射至关重要。相比之下，SNA 可以在不破坏真实噪声模型的情况下促进噪声多样性，使 SNA 在原始图像去噪领域中显得新颖且重要。

### 3.3 暗阴影校正

在这部分中，我们介绍了暗阴影的定义和机制，并阐明了在低光照原始图像去噪中纠正暗阴影的重要性。从实际的角度来看，传感器中像素阵列的属性会因像素而异 [41]。我们遵循业界通用术语“暗阴影”来描述这种空间非均匀性 [25]、[45]。通常，暗阴影代表读取噪声中的时间稳定成分，可以视为黑电平误差（BLE）[21], [51] 和固定图案噪声（FPN）[24], [41], [44], [52], [53] 的结合。BLE 是暗阴影的空间不变偏差，而 FPN 是空间变化图案。大多数去噪方法 [2], [10], [11], [12], [13], [20], [38], [54] 假设传感器噪声在时间维度上是零均值的。在理想假设中，噪声图像的期望值  $E(D_n)$  在数学上与映射目标  $D_c$  相同。然而，对于真实的传感器噪声，读取噪声的期望值  $E(N_{\text{read}})$  是非零的暗阴影，打破了理想假设。如果存在空间变化的暗阴影， $E(D_n)$  和干净图像  $D_c$  之间的映射将变成片段式的非单射映射。与理想假设相比，这相当于暗阴影向数据映射中引入额外的高频信息。根据深度学习的频率原理，高频信息难以被神经网络学习 [55], [56]。因此，只要数据包含暗阴影，数据映射的可学习性就是脆弱的。先前的研究尝试使用卷积神经网络（CNNs）去除由暗阴影引起的 FPN，然而，作为局部运算符的集合的 CNNs 无法在没有全局信息的情况下完全去除 FPN。因此，在去噪之前纠正暗阴影以简化数据映射和提高去噪性能是至关重要的。

通过 DSC 降低噪声模型的复杂性，神经网络可以准确拟合成对真实数据之间的数据映

射，从而促进去噪后图像的色彩准确。在这部分中，我们介绍并分析了我们开发的线性暗阴影模型。我们基于基于物理的成像模型和实验经验，将暗阴影建模为线性模型

$$N_{ds} = N_{FPNk} \times \text{iso} + N_{FPNb} + \text{BLE}(\text{iso}, t) \quad (3)$$

其中  $N_{FPNk}$  和  $N_{FPNb}$  是我们需要在暗阴影中回归的 FPN 的系数。同时 BLE 由于依赖于 iso 和曝光时间，同样可以表示为

$$\text{BLE}(\text{iso}, t) = k_t(\text{iso}) \times t + b_t(\text{iso}) \quad (4)$$

### 3.4 低光照原始图像去噪 (LRID) 数据集

数据质量不足也是成对真实数据之间数据映射脆弱可学习性的一个原因。数据质量不足体现在四个数据缺陷上：空间错位、强度错位、噪声基准真相、以及多样性不足，这些分别导致了错误的数据映射、有偏的数据映射、收敛性能差、以及过拟合的去噪模型。现有的去噪数据集至少存在上述缺陷中的一个重大问题。因此，现有数据集难以从数据角度满足低光照去噪的需求。我们的动机是从数据角度发展图像获取协议，并构建一个高质量的低光照原始图像去噪数据集。我们的协议通过精心设计的图像捕获设置解决了数据缺陷。我们的数据集将用于系统性地评估低光照原始图像去噪方法的性能。

在这一节中，我们首先详细介绍数据集的图像获取协议，然后介绍我们考虑暗阴影的噪声估计流程，最后展示我们基准真相估计方法的框架。

我们使用配备 IMX686 传感器的 Redmi K30 智能手机构建了一个高质量的数据集。这个低光照原始图像去噪 (LRID) 数据集包含 138 个场景，其中包括 82 个室内和 56 个室外场景，共计 5754 张图像。我们首先在 ISO-100 下拍摄了 25 张长曝光图像，然后立即在 ISO-6400 下拍摄了几组短曝光图像。最后，为了真实世界的低光照图像增强，我们捕获了智能手机原始 ISP 前后的一对长曝光图像。我们使用程序远程控制智能手机，图像获取的间隔非常短（大约 0.01 秒每帧），这意味着短曝光帧之间的错位可以忽略不计。室内场景是在不同色温和照明设置的封闭空间内拍摄的。每个场景有五组短曝光图像，长曝光和短曝光图像的曝光时间比分别为 64、128、256、512 和 1024。长曝光图像的总曝光时间约为 25 秒。室外场景是在午夜和平静的风（0.5 米/秒内）中拍摄的。每个场景有三组短曝光图像，长曝光和短曝光图像的曝光时间比分别为 64、128 和 256。长曝光图像的总曝光时间约为 64 秒。我们的图像获取协议之所以优越，是因为它解决了影响可学习性的四个数据缺陷。最大总曝光时间和最小曝光时间分别受空间对齐和强度对齐的限制。长曝光图像和短曝光图像的图像捕获设置分别为干净基准真相和充分多样性而设计。

以往的工作在估计干净基准真相方面有不同的观点。我们将它们归类为两种典型风格：“ELD 风格” [21] 和 “SIDD 风格” [48]。“ELD 风格” 通过在低 ISO 下收集长曝光图像作为干净基准真相。“SIDD 风格” 则通过融合多帧噪声图像（通常在高 ISO 下捕获）来估计干净基准真相。“ELD 风格” 在相同总曝光时间下噪声更少，而 “SIDD 风格” 可以灵活处理各种错位。为了尽快获得干净且清晰的基准真相，我们结合了 “ELD 风格” 和 “SIDD 风格”的优势。我们的干净基准真相是在低 ISO (“ELD 风格”) 下捕获的多个原始图像的融合 (“SIDD 风格”)。如图 8 所示，“ELD 风格” 在相同总曝光时间下比 “SIDD 风格” 更干净。“我们的方法” 表现出最干净和最清晰的结果。这种比较展示了我们长曝光图像捕获设置的必要性。数据多样

性可以从两个方面来看：场景多样性和噪声多样性。然而，不同相机收集的不同数据集可能具有不同的噪声模型，因此很难对它们进行定量比较。

先前的噪声估计工作 [21] 忽略了在临时变化噪声校准期间时间稳定的暗阴影的影响。我们提出了一种发展的噪声校准方法。我们记录平场帧以通过光子传输方法 [23] 估计系统增益  $K$ ，并记录暗帧以估计其他噪声参数。我们需要在估计其他噪声参数之前用暗帧校准暗阴影。接下来，为了避免由暗阴影引起的校准误差，我们需要在噪声参数校准之前对每个暗帧应用暗阴影校正 (DSC)。最后，我们应用现有的校准方法 [2], [21], [38] 来估计噪声参数。我们根据 P-G [38] 在 ISO-100 下记录了噪声参数  $K$  和  $6_{read}$  以用于后续的基准真相估计。我们进一步发展了基于暗阴影的缺陷像素检测方法 [48]。我们使用中值滤波器去除暗阴影的高频成分，以获得不存在异常值（包括缺陷像素）的低频成分。然后我们从暗阴影中减去低频成分，以获得几乎不包含低频空间偏差的高频成分。最后，我们将高频成分中值域在  $6_{read}$  范围外的所有像素视为缺陷像素，并记录它们的位置以用于缺陷像素校正。

这种发展的方法纠正了先前工作 [2], [21], [38], [48] 中读取噪声的零均值假设，并考虑了由暗阴影引入的低频空间偏差，可以准确地估计传感器的噪声参数。

## 4 复现细节

### 4.1 与已有开源代码对比

源代码中只提供特定参数下的已处理图片融合和训练，引用特定传感器下的参数，缺少包括图片拍摄，参数标定的代码和流程。

针对特定相机，使用 qt 和相机 sdk 开发了自动拍摄和参数校订的程序，方便特定传感器相机的数据采集与参数标定，实现包括用于 FPN 的图像采集和 BLE 的图像采集以及真实数据对的实时对焦后自动采集，复现了根据相应图片，自动拟合获取暗阴影参数的程序对于原文中提出的线性拟合暗阴影模型，在获取相应图片后，自动进行图片融合，以及对暗阴影的各部分参数进行线性拟合，同时存储在相应位置方便调用，同时另外复现暗阴影校正接口，同时进行了对应相应噪声参数的各种标定。

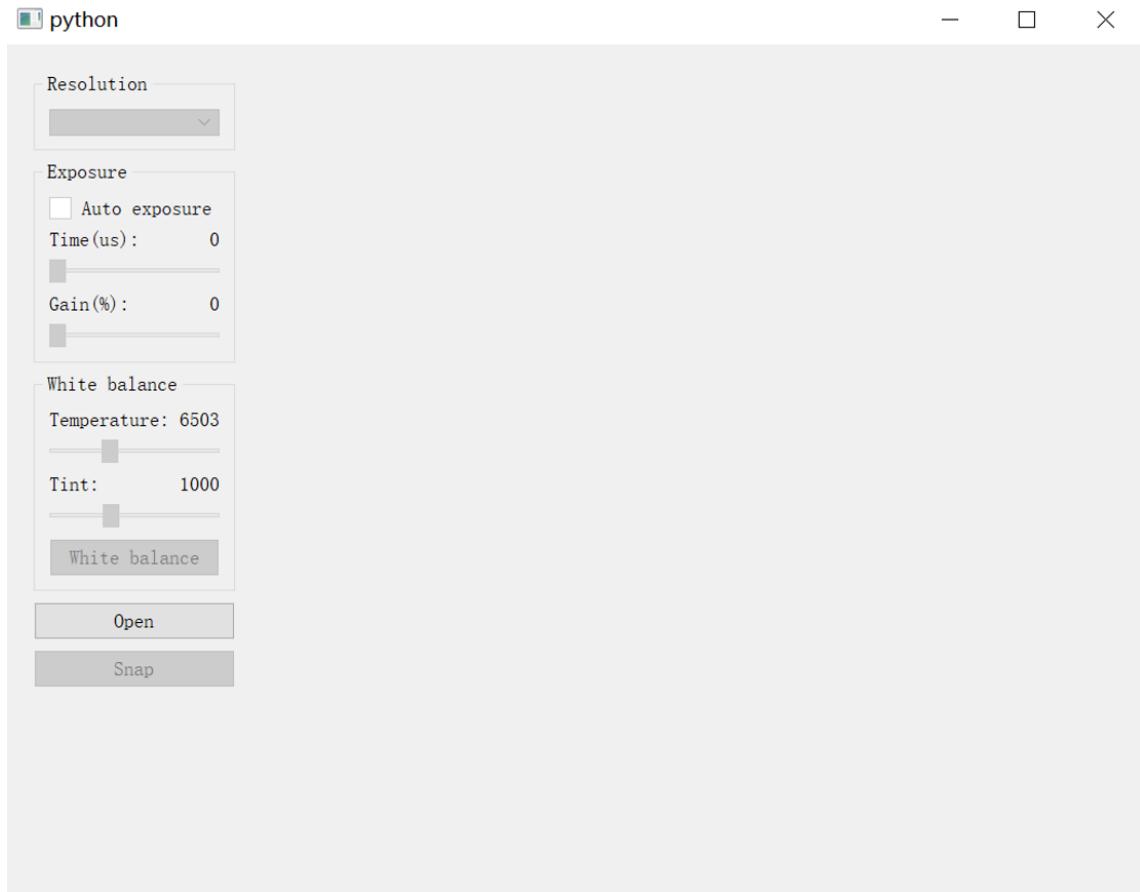


图 2. 配对数据集拍摄程序

## 4.2 创新点

获取数据集中干净图片时，通过保证曝光时间和增益系数乘积一定尽可能使得亮度对齐，同时从摄像机底层，尽量缩减拍摄间隔，实现全自动拍摄和处理以减少拍摄的影响。

本论文只做了散粒噪声数据增强，结合前面 ELD 的方法，通过合成噪声作更多的数据增强。

## 5 实验结果分析

我们使用与 SID [8] 和 ELD [21] 相同的 UNet 架构 [57]。在公共数据集上，使用 SID Sony 训练集的原始图像来创建训练数据。定量结果报告在 ELD Sony 数据集和整个 SID Sony 数据集上，包括验证和测试集。在我们的数据集上，90% 的场景用于训练，10% 的场景用于验证。由于室外和室内场景的图像获取协议不同，我们分别展示了他们的结果。DSC 应用于噪声原始图像，而 SNA 仅用于训练。有 75% 的概率训练数据对将通过 SNA 增强。SID 数据集和 ELD 数据集的校准基于 Sony A7S2 相机，该相机具有与公共数据集相同的传感器，但不是相同的相机。我们每个 ISO 收集 400 个暗帧用于暗校准 2，并将 t 设置为 0.1。我们将原始 Bayer 图像打包成四个通道，并采样每个图像的非重叠  $512 \times 512$  补丁，然后随机旋转和翻转它们作为一个批次。我们通过 Rawpy (LibRaw 的 Python 包装器) 将原始图像可视化为 sRGB 图像，以便观看，并遵循现有作品 [8], [21] 的真实元数据，定量结果在原始域上计算。为了展示我们策略的可靠性，我们将我们的方法与以下内容进行比较：使用基于不同噪声模

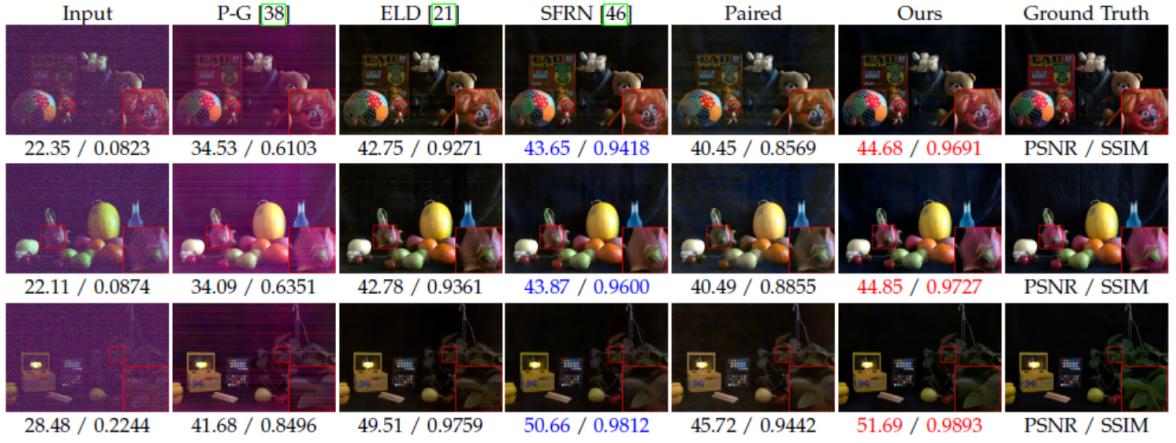


图 3. ELD 数据集方法比较

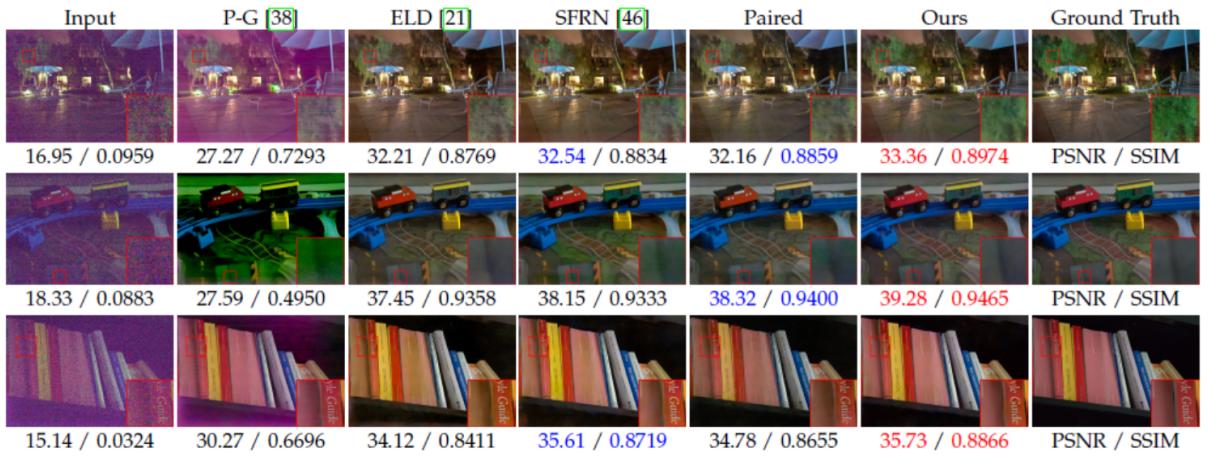


图 4. SID 数据集方法比较

型的合成数据训练的去噪模型，包括泊松-高斯（P-G） [38] 和 ELD [21]，这是低光原始图像去噪的经典方法。

公共数据集上的去噪结果显示在图 3 和图 4 中。使用合成数据训练的去噪模型无法完全去除复杂的真实噪声。P-G 与真实噪声模型相去甚远，导致性能有限。ELD 虽然考虑了更多的噪声来源，但仍然偏离真实噪声模型，导致色彩偏差和残留噪声。尽管 SFRN 采样了真实的读取噪声，但片段式方法无法从本质上解决由暗影引起的映射困境，导致残留的 FPN。成对的真实数据虽然包含真实噪声，但在可学习性方面如此脆弱，以至于去噪模型无法学习精确准确的数据映射，导致结果模糊和色彩偏差。通过将可学习性增强策略应用于成对的真实数据，去噪性能在定量结果和视觉质量上都得到了显著改善。我们的工作展示了最清晰的纹理和最精确的颜色的干净去噪结果。如图 5 所示，我们的方法在我们的数据集上展示了卓越的去噪性能，具有最清晰的纹理和最精确的颜色。这一性能与我们在公共数据集上的结果一致，表明我们方法的高度泛化性。



图 5. LRID 数据集方法比较

最终去噪效果如图 6和图 7所示，分别展示了室内和室外场景，评价指标为 PSNR 和 SSIM。



图 6. LRID 室内降噪效果对比



图 7. LRID 数据集室外降噪效果对比

## 6 总结与展望

在这篇论文中，从数据角度引入了一种用于低光原始图像去噪的可学习性增强策略，可学习性增强策略本质上突破了成对真实数据的可学习性瓶颈。该策略整合了三种高效方法：SNA、DSC 和一个发展的图像获取协议，这些帮助神经网络通过增加数据量、减少噪声复杂性和改善数据质量来高效地学习数据映射。基于发展的图像获取协议，同时构建了一个新的低光原始图像去噪数据集。在公共数据集和该数据集上的广泛实验集体展示了此方法在低光原始图像去噪上的优越性。

由于标定参数的繁琐性，可以引入学习的方法进行参数标定和噪声合成，依赖于参数的分阶段标定，学习过程同样可以分阶段进行，保证学习到的参数有一定的可解释性。

## 参考文献

- [1] Samuel W Hasinoff, Dillon Sharlet, Ryan Geiss, Andrew Adams, Jonathan T Barron, Florian Kainz, Jiawen Chen, and Marc Levoy. Burst photography for high dynamic range and low-light imaging on mobile cameras. *ACM Transactions on Graphics (ToG)*, 35(6):1–12, 2016.
- [2] Yuzhi Wang, Haibin Huang, Qin Xu, Jiaming Liu, Yiqun Liu, and Jue Wang. Practical deep raw image denoising on mobile devices. In *European Conference on Computer Vision*, pages 1–16. Springer, 2020.
- [3] Ian S McLean et al. *Electronic imaging in astronomy: detectors and instrumentation*, volume 552. Springer, 2008.
- [4] Ben Moseley, Valentin Bickel, Ignacio G. López-Francos, and Loveneesh Rana. Extreme low-light environment-driven image denoising over permanently shadowed lunar regions with a physical noise model. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 6313–6323, 2021.
- [5] Matthew S Joens, Chuong Huynh, James M Kasuboski, David Ferranti, Yury J Sigal, Fabian Zeitvogel, Martin Obst, Claus J Burkhardt, Kevin P Curran, Sreekanth H Chalasani, et al. Helium ion microscopy (him) for the imaging of biological samples at sub-nanometer resolution. *Scientific reports*, 3(1):3514, 2013.
- [6] Chongyi Li, Chunle Guo, Linghao Han, Jun Jiang, Ming-Ming Cheng, Jinwei Gu, and Chen Change Loy. Low-light image and video enhancement using deep learning: A survey. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(12):9396–9416, 2022.
- [7] Haofeng Huang, Wenhan Yang, Yueyu Hu, Jiaying Liu, and Ling-Yu Duan. Towards low light enhancement with raw images. *IEEE Transactions on Image Processing*, 31:1391–1405, 2022.
- [8] Chen Chen, Qifeng Chen, Jia Xu, and Vladlen Koltun. Learning to see in the dark. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 3291–3300, 2018.
- [9] Halbert White. Connectionist nonparametric regression: Multilayer feedforward networks can learn arbitrary mappings. *Neural networks*, 3(5):535–549, 1990.
- [10] Kai Zhang, Wangmeng Zuo, Yunjin Chen, Deyu Meng, and Lei Zhang. Beyond a gaussian denoiser: Residual learning of deep cnn for image denoising. *IEEE Transactions on Image Processing*, 26(7):3142–3155, 2017.
- [11] Kai Zhang, Wangmeng Zuo, and Lei Zhang. Ffdnet: Toward a fast and flexible solution for cnn-based image denoising. *IEEE Transactions on Image Processing*, 27(9):4608–4622, 2018.

- [12] Shi Guo, Zifei Yan, Kai Zhang, Wangmeng Zuo, and Lei Zhang. Toward convolutional blind denoising of real photographs. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 1712–1722, 2019.
- [13] Zongsheng Yue, Hongwei Yong, Qian Zhao, Deyu Meng, and Lei Zhang. Variational denoising network: Toward blind noise modeling and removal. *Advances in neural information processing systems*, 32, 2019.
- [14] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, Ming-Hsuan Yang, and Ling Shao. Multi-stage progressive image restoration. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 14816–14826, 2021.
- [15] Shen Cheng, Yuzhi Wang, Haibin Huang, Donghao Liu, Haoqiang Fan, and Shuaicheng Liu. Nbnnet: Noise basis learning for image denoising with subspace projection. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 4894–4904, 2021.
- [16] Zhengzhong Tu, Hossein Talebi, Han Zhang, Feng Yang, Peyman Milanfar, Alan Bovik, and Yinxiao Li. Maxim: Multi-axis mlp for image processing. In *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5759–5770, 2022.
- [17] Liangyu Chen, Xin Lu, Jie Zhang, Xiaojie Chu, and Chengpeng Chen. Hinet: Half instance normalization network for image restoration. In *2021 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 182–192, 2021.
- [18] Syed Waqas Zamir, Aditya Arora, Salman Khan, Munawar Hayat, Fahad Shahbaz Khan, and Ming-Hsuan Yang. Restormer: Efficient transformer for high-resolution image restoration. In *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 5718–5729, 2022.
- [19] Tim Brooks, Ben Mildenhall, Tianfan Xue, Jiawen Chen, Dillon Sharlet, and Jonathan T. Barron. Unprocessing images for learned raw denoising. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 11028–11037, 2019.
- [20] Kaixuan Wei, Ying Fu, Jiaolong Yang, and Hua Huang. A physics-based noise formation model for extreme low-light raw denoising. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2755–2764, 2020.
- [21] Kaixuan Wei, Ying Fu, Yinqiang Zheng, and Jiaolong Yang. Physics-based noise modeling for extreme low-light photography. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 44(11):8520–8537, 2022.
- [22] James Janesick, Kenneth Klaasen, and Tom Elliott. Ccd charge collection efficiency and the photon transfer technique. In *Solid-state imaging arrays*, volume 570, pages 7–19. SPIE, 1985.

- [23] G.E. Healey and R. Kondepudy. Radiometric ccd camera calibration and noise estimation. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 16(3):267–276, 1994.
- [24] Lingfei Song and Hua Huang. Fixed pattern noise removal based on a semi-calibration method. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 45(10):11842–11855, 2023.
- [25] A Theuwissen. How to measure the dark shading. *URL: <https://harvestimaging.com/blog>*, 2011.
- [26] Hansen Feng, Lizhi Wang, Yuzhi Wang, Haoqiang Fan, and Hua Huang. Learnability enhancement for low-light raw image denoising: A data perspective. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, 46(1):370–387, 2024.
- [27] Hansen Feng, Lizhi Wang, Yuzhi Wang, and Hua Huang. Learnability enhancement for low-light raw denoising: Where paired real data meets noise modeling. In *Proceedings of the 30th ACM International Conference on Multimedia*, pages 1436–1444, 2022.
- [28] J. Portilla, V. Strela, M.J. Wainwright, and E.P. Simoncelli. Image denoising using scale mixtures of gaussians in the wavelet domain. *IEEE Transactions on Image Processing*, 12(11):1338–1351, 2003.
- [29] Leonid I Rudin, Stanley Osher, and Emad Fatemi. Nonlinear total variation based noise removal algorithms. *Physica D: nonlinear phenomena*, 60(1-4):259–268, 1992.
- [30] A. Buades, B. Coll, and J.-M. Morel. A non-local algorithm for image denoising. In *2005 IEEE Computer Society Conference on Computer Vision and Pattern Recognition (CVPR'05)*, volume 2, pages 60–65 vol. 2, 2005.
- [31] Kostadin Dabov, Alessandro Foi, Vladimir Katkovnik, and Karen Egiazarian. Image denoising by sparse 3-d transform-domain collaborative filtering. *IEEE Transactions on Image Processing*, 16(8):2080–2095, 2007.
- [32] Matteo Maggioni, Giacomo Boracchi, Alessandro Foi, and Karen Egiazarian. Video denoising, deblocking, and enhancement through separable 4-d nonlocal spatiotemporal transforms. *IEEE Transactions on Image Processing*, 21(9):3952–3966, 2012.
- [33] Michael Elad and Michal Aharon. Image denoising via sparse and redundant representations over learned dictionaries. *IEEE Transactions on Image Processing*, 15(12):3736–3745, 2006.
- [34] M. Aharon, M. Elad, and A. Bruckstein. K-svd: An algorithm for designing overcomplete dictionaries for sparse representation. *IEEE Transactions on Signal Processing*, 54(11):4311–4322, 2006.

- [35] Shuhang Gu, Lei Zhang, Wangmeng Zuo, and Xiangchu Feng. Weighted nuclear norm minimization with application to image denoising. In *2014 IEEE Conference on Computer Vision and Pattern Recognition*, pages 2862–2869, 2014.
- [36] Chen Chen, Qifeng Chen, Minh Do, and Vladlen Koltun. Seeing motion in the dark. In *2019 IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 3184–3193, 2019.
- [37] Huanjing Yue, Cong Cao, Lei Liao, Ronghe Chu, and Jingyu Yang. Supervised raw video denoising with a benchmark dataset on dynamic scenes. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2298–2307, 2020.
- [38] Alessandro Foi, Mejdi Trimeche, Vladimir Katkovnik, and Karen Egiazarian. Practical poissonian-gaussian noise modeling and fitting for single-image raw-data. *IEEE Transactions on Image Processing*, 17(10):1737–1754, 2008.
- [39] Markku Makitalo and Alessandro Foi. A closed-form approximation of the exact unbiased inverse of the anscombe variance-stabilizing transformation. *IEEE Transactions on Image Processing*, 20(9):2697–2698, 2011.
- [40] Markku Makitalo and Alessandro Foi. Optimal inversion of the generalized anscombe transformation for poisson-gaussian noise. *IEEE Transactions on Image Processing*, 22(1):91–103, 2013.
- [41] Bernd Jähne. Emva 1288 standard for machine vision: Objective specification of vital camera data. *Optik & Photonik*, 5(1):53–54, 2010.
- [42] Hans Wach and Edward R Dowski Jr. Noise modeling for design and simulation of computational imaging systems. In *Visual Information Processing XIII*, volume 5438, pages 159–170. SPIE, 2004.
- [43] Ryan D. Gow, David Renshaw, Keith Findlater, Lindsay Grant, Stuart J. McLeod, John Hart, and Robert L. Nicol. A comprehensive tool for modeling cmos image-sensor-noise performance. *IEEE Transactions on Electron Devices*, 54(6):1321–1329, 2007.
- [44] Mikhail Konnik and James Welsh. High-level numerical simulations of noise in ccd and cmos photosensors: review and tutorial. *arXiv preprint arXiv:1412.4031*, 2014.
- [45] Junichi Nakamura. *Image sensors and signal processing for digital still cameras*. CRC press, 2017.
- [46] Yi Zhang, Hongwei Qin, Xiaogang Wang, and Hongsheng Li. Rethinking noise synthesis and modeling in raw denoising. In *2021 IEEE/CVF International Conference on Computer Vision (ICCV)*, pages 4573–4581, 2021.

- [47] Tobias Plötz and Stefan Roth. Benchmarking denoising algorithms with real photographs. In *2017 IEEE Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 2750–2759, 2017.
- [48] Abdelrahman Abdelhamed, Stephen Lin, and Michael S. Brown. A high-quality denoising dataset for smartphone cameras. In *2018 IEEE/CVF Conference on Computer Vision and Pattern Recognition*, pages 1692–1700, 2018.
- [49] Abhijith Punnappurath, Abdullah Abuolaim, Abdelrahman Abdelhamed, Alex Levin-shtain, and Michael S. Brown. Day-to-night image synthesis for training nighttime neural ips. In *2022 IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR)*, pages 10759–10768, 2022.
- [50] Jiaming Liu, Chi-Hao Wu, Yuzhi Wang, Qin Xu, Yuqian Zhou, Haibin Huang, Chuan Wang, Shaofan Cai, Yifan Ding, Haoqiang Fan, and Jue Wang. Learning raw image denoising with bayer pattern unification and bayer preserving augmentation. In *2019 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pages 2070–2077, 2019.
- [51] Jing Wang, Yitong Yu, Songtao Wu, Chang Lei, and Kuanhong Xu. Rethinking noise modeling in extreme low-light environments. In *2021 IEEE International Conference on Multimedia and Expo (ICME)*, pages 1–6, 2021.
- [52] Matteo Maggioni, Enrique Sánchez-Monge, and Alessandro Foi. Joint removal of random and fixed-pattern noise through spatiotemporal video filtering. *IEEE Transactions on Image Processing*, 23(10):4282–4296, 2014.
- [53] Gerald C Holst. Cmos/ccd sensors and camera systems. *CMOS/CCD sensors and camera systems/Gerald C. Holst*, 2007.
- [54] Jaakko Lehtinen, Jacob Munkberg, Jon Hasselgren, Samuli Laine, Tero Karras, Miika Aittala, and Timo Aila. Noise2noise: Learning image restoration without clean data. *arXiv preprint arXiv:1803.04189*, 2018.
- [55] Zhi-Qin John Xu, Yaoyu Zhang, and Yanyang Xiao. Training behavior of deep neural network in frequency domain. In *Neural Information Processing: 26th International Conference, ICONIP 2019, Sydney, NSW, Australia, December 12–15, 2019, Proceedings, Part I 26*, pages 264–274. Springer, 2019.
- [56] Zhi-Qin John Xu, Yaoyu Zhang, and Yanyang Xiao. Training behavior of deep neural network in frequency domain. In *Neural Information Processing: 26th International Conference, ICONIP 2019, Sydney, NSW, Australia, December 12–15, 2019, Proceedings, Part I 26*, pages 264–274. Springer, 2019.

- [57] Olaf Ronneberger, Philipp Fischer, and Thomas Brox. U-net: Convolutional networks for biomedical image segmentation. In *Medical Image Computing and Computer-Assisted Intervention–MICCAI 2015: 18th International Conference, Munich, Germany, October 5–9, 2015, Proceedings, Part III* 18, pages 234–241. Springer, 2015.